

Chapitre 3

Étude d'une variable statistique bivarié

Dans les chapitres précédents, nous avons présenté les méthodes qui permettent de résumer et représenter les informations relatives à une variable. Un même individu peut être étudié à l'aide de plusieurs caractères (ou variables). Par exemple, les salaires en regardant leur ancienneté et leur niveau d'étude, la croissance d'un enfant en regardant son poids et sa taille. Dans la suite, nous introduisons l'étude globale des relations entre deux variables (en nous limitant au cas de deux variables). Donc, soit Ω une population finie, E et F deux ensembles

3.1 Définitions

Définition 3.1. On appelle série statistique bivarié (ou double) sur ω ., toute application C définie par

$$\begin{aligned} C : \Omega &\rightarrow E \times F \\ \omega &\mapsto (X(\omega), Y(\omega)). \end{aligned}$$

Exemple 3.1.

- 1) A chaque individu, on associe son poids (X) et sa taille (Y).
- 2) A chaque voiture, on associe sa marque (X) et sa couleur (Y).

Définition 3.2. Soit $C = (X, Y)$ une série statistique double, on suppose que

$$X(\omega) = \{x_1, x_2, \dots, x_p\} \text{ et } Y(\omega) = \{y_1, y_2, \dots, y_q\}$$

on pose par définition

1. L'effectif du couple (x_i, y_j) : On appelle l'effectif du couple (x_i, y_j) , le nombre

$$n_{ij} = \text{Card}\{\omega \in \Omega : C(\omega) = (x_i, y_j)\}.$$

De plus, on a l'effectif total

$$N = \text{Card}(\Omega) = \sum_{i=1}^p \sum_{j=1}^q n_{ij}$$

2. L'effectif associé à la modalité : On appelle effectif associé à la modalité x_i (resp y_j) le nombre

$$n_{i\bullet} = \sum_{j=1}^q n_{ij} \text{ resp } (n_{\bullet j} = \sum_{i=1}^p n_{ij}).$$

la famille $(x_i, n_{i\bullet})_{i \in \{1,2,\dots,p\}}$ s'appelle la première série marginale et la famille $(n_{\bullet j}, y_j)_{j \in \{1,2,\dots,q\}}$ s'appelle la deuxième série marginale.

3. Les série statistiques :

— On note aussi la série statistique double précédente par

$$C = (X, Y) = ((x_i, y_j), n_{ij})_{(i,j) \in \{1,2,\dots,p\} \times \{1,2,\dots,q\}}$$

- la famille $(x_i, n_{i\bullet})_{i \in \{1,2,\dots,p\}}$ s'appelle la première série marginale.
- la famille $(n_{\bullet j}, y_j)_{j \in \{1,2,\dots,q\}}$ s'appelle la deuxième série marginale.
- Pour j fixé, la famille $(x_i, n_{ij})_{i \in \{1,2,\dots,p\}}$ s'appelle la série statistique conditionnelle de X sachant que le second caractère Y vaut y_j , on la note $X_{/Y=y_j}$
- Pour i fixé, la famille $(y_j, n_{ij})_{j \in \{1,2,\dots,q\}}$ s'appelle la série statistique conditionnelle de Y sachant que le premier caractère X vaut x_i , on la note $Y_{/X=x_i}$.

4. Les fréquences :

- Le nombre $f_{ij} = \frac{n_{ij}}{N}$ est appelé la fréquence du couple (x_i, y_j) ou fréquence conjointe, de plus on a $\sum_{i=1}^p \sum_{j=1}^q f_{ij} = 1$
- Les nombres $f_{i\bullet} = \frac{n_{i\bullet}}{N}$ et $f_{\bullet j} = \frac{n_{\bullet j}}{N}$ sont appelés les fréquence marginales.

Remarque 3.1. Pour déterminer les séries statistiques marginales d'une série double, il suffit donc d'ajouter une colonne à droite du tableau statistique pour placer les sommes des $n_{i\bullet}$, de même $n_{\bullet j}$ s'obtient en faisant la somme des éléments de la j^{eme} colonne, d'où le nom de séries "marginales".

Exemple 3.2. Nous effectuons un sondage auprès de nos étudiants en leur demandant leur note de mathématique au baccalauréat et le nombre de redoublements au cours de leur scolarité primaire et secondaire. Les résultats bruts obtenus sont les suivants :

$$\begin{aligned} &(0; 14) - (1; 14) - (0; 14) - (2; 11) - (1; 12) - (2; 11) - (1; 13) - (2; 13) - (1; 12) \\ &(0; 12) - (1; 14) - (0; 14) - (0; 11) - (1; 12) - (3; 10) - (1; 13) - (3; 13) - (0; 12) \\ &(3; 14) - (0; 14) - (0; 13) - (1; 14) - (0; 13) - (0; 11) - (3; 10). \end{aligned}$$

Soit X le caractère "nombre de redoublements" et Y le caractère "note au bac". Les tableaux statistiques des série simple X , Y et de la série statistique double regroupant les données sont :

TABLE 3.1

x_i	0	1	2	3
n_i	10	8	3	4

TABLE 3.2

y_i	10	11	12	13	14
n_i	2	4	5	6	8

TABLE 3.3

$X \setminus Y$	10	11	12	13	14	$n_{i\bullet}$
0	0	2	2	2	4	10
1	0	0	3	2	3	8
2	0	2	0	1	0	3
3	2	0	0	1	1	4
$n_{\bullet j}$	2	4	5	6	8	25

3.2 Paramètres de distribution marginales

On considère la série statistique double $C = ((x_i, y_j), n_{ij})_{(i,j) \in \{1,2,\dots,p\} \times \{1,2,\dots,q\}}$. On définit les caractéristiques marginales par

1. La moyenne marginale en X :

$$\bar{X} = \frac{1}{N} \sum_{i=1}^p n_{i\bullet} x_i.$$

2. La variance marginale en X : le nombre réel positif défini par

$$V(X) = \frac{1}{N} \sum_{i=1}^q n_{i\bullet} (x_i - \bar{X})^2.$$

3. L'écart type marginale en X : le nombre réel positif défini par

$$\sigma(X) = \sigma_X = \sqrt{V(X)}.$$

de meme

1. La moyenne marginale en Y :

$$\bar{Y} = \frac{1}{N} \sum_{i=1}^p n_{\bullet j} y_j.$$

2. La variance marginale en Y : le nombre réel positif définit par

$$V(Y) = \frac{1}{N} \sum_{i=1}^q n_{\bullet j} (y_j - \bar{Y})^2.$$

3. L'écart type marginale en en X : le nombre réel positif définit par

$$\sigma(Y) = \sigma_Y = \sqrt{V(Y)}.$$

Exemple 3.3. On considère le tableau 3.3, on a :

1. La moyenne marginale en X :

$$\begin{aligned} \bar{X} &= \frac{1}{N} \sum_{i=1}^p n_{i\bullet} x_i \\ &= \frac{10 \times 0 + 8 \times 1 + 3 \times 2 + 4 \times 3}{25} = 1,04. \end{aligned}$$

2. La variance marginale en X :

$$\begin{aligned} V(X) &= \frac{1}{N} \sum_{i=1}^q n_{i\bullet} (x_i - \bar{X})^2 \\ &= \frac{10 \times (0 - 1,04)^2 + 8 \times (1 - 1,04)^2 + 3 \times (2 - 1,04)^2 + 4 \times (3 - 1,04)^2}{25} \\ &= 1,15. \end{aligned}$$

3. L'écart type marginale en en X :

$$\sigma(X) = \sigma_X = \sqrt{V(X)} = 1,07.$$

de meme

1. La moyenne marginale en Y :

$$\begin{aligned} \bar{Y} &= \frac{1}{N} \sum_{j=1}^q n_{\bullet j} y_j \\ &= \frac{10 \times 2 + 4 \times 11 + 5 \times 12 + 6 \times 13 + 8 \times 14}{25} = 12,56. \end{aligned}$$

2. La variance marginale en X :

$$\begin{aligned} V(Y) &= \frac{1}{N} \sum_{j=1}^q n_{\bullet j} (y_j - \bar{Y})^2 \\ &= \frac{2 \times (-2,56)^2 + 4 \times (-1,56)^2 + 5 \times (-0,56)^2 + 6 \times (0,44)^2 + 8 \times (1,44)^2}{25} \\ &= 3,65. \end{aligned}$$

3. L'écart type marginale en en X :

$$\sigma(Y) = \sigma_Y = \sqrt{V(Y)} = 1,89.$$

3.3 Paramètres de distribution conditionnelles

On considère la série statistique double $C = ((x_i, y_j), n_{ij})_{(i,j) \in \{1,2,\dots,p\} \times \{1,2,\dots,q\}}$. On définit les caractéristique marginales par

1. La fréquence conditionnelle de x_i sachant y_j :

$$f_{i/j} = \frac{n_{ij}}{n_{\bullet j}}.$$

2. La fréquence conditionnelle de y_j sachant x_i :

$$f_{j/i} = \frac{n_{ij}}{n_{i\bullet}}.$$

3. La distribution $(x_i, f_{i/j})_{i \in \{1,2,\dots,p\}}$ est appelée la distribution conditionnelle des fréquences de X sachant que $Y = y_j$.
4. La distribution $(y_j, f_{j/i})_{j \in \{1,2,\dots,q\}}$ est appelée la distribution conditionnelle des fréquences de Y sachant que $X = x_i$.

Chapitre 4

Ajustement linéaire

4.1 Indépendance

Proposition 4.1. On considère les deux distributions $(x_i, f_{i/j})_{i \in \{1,2,\dots,p\}}$ et $(y_j, f_{j/i})_{j \in \{1,2,\dots,q\}}$ on a

$$\forall (i, j) \in \{1, 2, \dots, p\} \times \{1, 2, \dots, q\}, f_{ij} = f_{i/j} \times f_{\bullet j} = f_{j/i} \times f_{i\bullet}$$

Définition 4.1. On considère les deux distributions $(x_i, f_{i/j})_{i \in \{1,2,\dots,p\}}$ et $(y_j, f_{j/i})_{j \in \{1,2,\dots,q\}}$, on dit que les caractères observés X et Y sont statistiquement indépendants si et seulement si

$$\forall (i, j) \in \{1, 2, \dots, p\} \times \{1, 2, \dots, q\}, f_{ij} = f_{\bullet j} \times f_{i\bullet}$$

Autrement dit

$$f_{i/j} = f_{\bullet j} = f_{i\bullet}$$

4.2 Covariance

Définition 4.2. On considère la série statistique double $C = ((x_i, y_j), n_{ij})_{(i,j) \in \{1,2,\dots,p\} \times \{1,2,\dots,q\}}$. On définit la covariance du couple (X, Y) et on note $cov(X, Y)$ (ou σ_{xy}) la moyenne :

$$cov(X, Y) = \sigma_{xy} = \frac{1}{N} \sum_{i=1}^p \sum_{j=1}^q n_{ij} (x_i - \bar{X})(y_j - \bar{Y})$$

Proposition 4.2. Soit (X, Y) une statistique double et soit $a, b (a \neq 0)$ deux réels. Alors on a :

1. $cov(X, Y) = (\frac{1}{N} \sum_{i=1}^p \sum_{j=1}^q n_{ij} x_i y_j) - (\bar{X}\bar{Y})$.
2. $cov(X, X) = V(X)$.
3. La symétrie : $cov(X, Y) = cov(Y, X)$
4. La linéarité par rapport à X : $cov(a.X + b, Y) = acov(X, Y)$
5. La linéarité par rapport à Y : $cov(X, a.Y + b) = acov(X, Y)$

Remarque 4.1. La covariance peut prendre des valeurs positives, négatives ou nulles.

4.3 Coefficient de corrélation

Définition 4.3. On considère la série statistique double $C = ((x_i, y_j), n_{ij})_{(i,j) \in \{1,2,\dots,p\} \times \{1,2,\dots,q\}}$. On suppose que $\sigma_x \neq 0$ et $\sigma_y \neq 0$. On définit le coefficient de corrélation linéaire, le nombre réel :

$$\rho(X, Y) = \rho_{xy} = \frac{\text{cov}(X, Y)}{\sigma_x \times \sigma_y}$$

Proposition 4.3. Soit (X, Y) une statistique double tel que $\sigma_x \neq 0$ et $\sigma_y \neq 0$. . Alors on a :

$$-1 \leq \rho(X, Y) \leq 1.$$

Proposition 4.4. Soit (X, Y) une statistique double tel que $\sigma_x \neq 0$ et $\sigma_y \neq 0$. .


$$\text{Si } Y = aX + b (a \neq 0) \neq \text{ Alors on a : } \rho(X, Y) = \pm 1.$$

Remarque 4.2. 1. Le coefficient de corrélation dit de " Pearson " n'est pas sensible aux unités de chacune des variables.

2. Si $\rho(X, Y) = 1$ alors l'une des variables est fonction affine croissante de l'autre, de plus la corrélation est dite positive parfaite.
3. Si $\rho(X, Y) = -1$ alors l'une des variables est fonction affine décroissante de l'autre, de plus la corrélation est dite négative parfaite. .
4. Plus le coefficient est proche des valeurs extremes -1 et 1 , plus la corrélation linéaire entre les variables est forte.
5. Une corrélation égale à 0 signifie que les variables sont linéairement indépendantes.
6. Il ne faut pas croire qu'un coefficient de corrélation élevé induit une relation de causalité entre les deux caractères mesurés.


Exemple 4.1. 1. Forte corrélation linéaire positive :

Corrélation linéaire forte




2. Forte corrélation linéaire négative :


Corrélation linéaire forte




3. Faible corrélation négative : liaison exponentielle.



4. Pas de corrélation linéaire : Liaison parabolique.




5. Pas de corrélation linéaire : variables indépendantes.



4.4 La méthode de moindres carrés

L'idée la méthode de moindres carrés est de transformer un nuage de point en une droite. Celle-ci doit être la plus proche possible de chacun des points. On cherchera donc à minimiser les écarts entre les points et la droite. voir la figure suivante :



Pour cela, on cherche une droite $Y = aX + b$ telle que la distance entre le nuage de points et droite soit minimale, c'est à dire la différence entre le point réellement observé et le point prédit par la droite. Ainsi, la méthode des moindres carrés consiste à chercher la valeur des paramètres a et b qui minimise la somme des erreurs élevées au carré. Soit $M_i(x_i, y_i)$ un point de N point du nuage, on pose

$$U(a, b) = \sum_i^n e_i^2 = \sum_i^n (y_i - ax_i - b)^2.$$

La méthode des moindres carrées consiste donc à minimiser la fonction U (la somme

des erreurs commises). Nous avons la condition de minimisation suivante,

$$\frac{\partial U}{\partial a} = \frac{\partial U}{\partial b} = 0$$

On a donc,

$$\begin{cases} \frac{\partial U}{\partial a} = \sum_i^N (-2x_i)(y_i - ax_i - b), & ; \\ \frac{\partial U}{\partial b} = \sum_i^N (-2)(y_i - ax_i - b), & . \end{cases}$$

Après les calculs, on trouve

$$\begin{cases} \sum_i^N x_i y_i - a \sum_i^N x_i^2 - bN\bar{X} = 0, & ; \\ \sum_i^N y_i - a \sum_i^N x_i - bN = 0, & . \end{cases}$$

En multipliant la 1^{ère} équation par $\frac{1}{N}$ et la 2^{ème} équation par $-\frac{1}{N}\bar{X}$, nous obtenons le système suivant :

$$\begin{cases} \frac{1}{N} \sum_i^N x_i y_i - a \frac{1}{N} \sum_i^N x_i^2 - b\bar{X} = 0 & ; \\ -\bar{X} \bar{Y} + a\bar{X}^2 - b\bar{X} = 0 & . \end{cases}$$

En faisant la somme terme à terme des deux équations (1) et (2), on obtient

$$Cov(X, Y) - aV(X) = 0$$

ce qui donne

$$a = \frac{Cov(X, Y)}{V(X)}, \text{ et } b = \bar{Y} - a\bar{X}.$$

de plus on a

$$\min_{(a,b) \in \mathbb{R}^2} U(a, b) = N \frac{V(X)V(Y) - Cov(X, Y)^2}{V(X)} \geq 0.$$

4.5 La droite de régression

Dans le cas où on peut mettre en évidence l'existence d'une relation linéaire significative entre deux caractères quantitatifs continus X et Y, on peut chercher à formaliser la relation moyenne entre ces deux variables à l'aide d'une équation de droite qui résume cette relation. Les calculs et les résultats précédents se généralisent aisément au cas où la statistique double $C = (X, Y) = ((x_i, y_j), n_{ij})_{(i,j) \in \{1,2,\dots,p\} \times \{1,2,\dots,q\}}$ n'est pas injective. on définit cette droite appelée droite de regression par

Définition 4.4. 1. La droite d'équation $(D_{Y/X}) : y = ax + b$ avec $a = \frac{Cov(X,Y)}{V(X)}$, et $b = \bar{Y} - a\bar{X}$, s'appelle droite de régression de Y dans X.
2. La droite d'équation $(D_{X/Y}) : x = \alpha x + \beta$ avec $\alpha = \frac{Cov(X,Y)}{V(Y)}$, et $\beta = \bar{X} - \alpha\bar{Y}$, s'appelle droite de régression de X dans Y.

Proposition 4.5. Les deux droites de régression $(D_{Y/X})$ et $(D_{X/Y})$ passent par le même point de coordonnées $(\bar{X}, \bar{Y})$

Remarque 4.3. On admet généralement qu'un coefficient de corrélation $|\rho(X, Y)| \geq 0.75$ justifie la recherche d'un alignement statistique, en l'absence de renseignements complémentaires.

Deuxième partie

Probabilités

Introduction

A l'origine, dans les traductions d'Aristote , le mot "probabilité" ne désigne pas une quantification du caractère aléatoire d'un fait mais l'idée qu'une idée est communément admise par tous. Il faudra attendre le milieu du XVIIe siècle pour que ce mot prenne son sens actuel avec le début du traitement mathématique du sujet par Blaise Pascal et Pierre de Fermat. Ce n'est alors qu'au XIXe siècle qu'apparaît ce qui peut être considéré comme la théorie moderne des probabilités en mathématiques. Actuellement, Les probabilités sont une branche des Mathématiques dont l'objet est l'étude des phénomènes aléatoires ou non déterministes. Les objectifs de la théorie des probabilités sont :

1. Décrit le comportement de phénomènes dont le résultat est soumis au hasard,
2. Permet de modéliser la fréquence de réalisation d'« événements » aléatoires.

La théorie des probabilités trouve actuellement des applications dans plusieurs domaines allant de la musique à la physique et dans l'expérience quotidienne, de la prédiction de climat à la prédiction des risques de nouveaux traitements médicaux.